

Universidade do Minho
Escola de Engenharia

Eduarda Pereira PG61516
Gonçalo Ferreira PG61525
Gonçalo Magalhães PG61524
Jéssica Cunha PG60267

Previsão de Fluxo de Tráfego Rodoviário na Cidade do Porto

Dados e Aprendizagem Automática
Mestrado em Engenharia Informática

Índice

1	Introdução	6
2	Metodologia	7
3	Definição do Problema	8
3.1	Contexto do Problema	8
3.2	Objetivo Principal	8
3.3	Relevância do Problema	8
3.4	Métrica de Avaliação	9
	Observação e Ingestão	11
4.1	Fonte de Dados	11
4.2	Análise de Dados e Taxonomia	11
4.3	Visualização e Insights Críticos	12
4.3.1	Distribuição do Alvo e Desequilíbrio	12
4.3.2	Matriz de Correlação e SHAP Values	12
4.3.3	Análise de Clustering e Sobreposição	13
5	Preparação de Dados	14
5.1	Tratamento de Atributos Categóricos	14
5.2	Tratamento de Missing Values e Conversão Numérica	14
5.2.1	Caso Especial – average_cloudiness	14
5.3	<i>Feature Engineering</i>	14
5.3.1	Representação do Dia da Semana	14
5.3.2	Indicadores de Períodos Críticos (Flags)	15
5.3.3	Codificação Cíclica (Cyclical Encoding)	15
5.4	Normalização e Escalonamento	15
5.5	Análise Comparativa de Estratégias	15
5.6	Estratégia de Otimização de Hiperparâmetros	16
5.6.1	Limitações da Procura Exaustiva (Grid Search)	16
5.6.2	Eficiência da Procura Aleatória (Randomized Search)	17
6	Modelação	18
6.1	Análise de Padrões e Não-Supervisionada	18
6.1.1	Experiência 9: Análise de Clustering e Sobreposição de Classes	18

6.2	A Tentativa com Deep Learning e o Overfitting	19
6.3	Otimização de Ensembles e AutoML	20
6.4	A Solução Especialista (One-Vs-Rest)	20
6.5	Síntese de Resultados e Reprodutibilidade	21
6.6	Detalhes de Reprodutibilidade (Hiperparâmetros)	21
7	Avaliação	23
7.1	Análise de Erros e Matriz de Confusão	23
7.1.1	O Problema do Ruído (SMOTE)	23
7.1.2	Análise da Solução Final (Especialistas)	24
8	Conclusão e Trabalho Futuro	25
8.1	Síntese do Trabalho Desenvolvido	25
8.2	Reflexão Crítica: A Lição dos Dados	25
8.3	Trabalho Futuro	26
	Bibliografia	27

Índice de Figuras

Distribuição dos dados	12
Matriz de Correlação	13
Visualização da projeção PCA e dos centroides gerados pelo K-Means	19
Comparação das matrizes de confusão: SMOTE (a) versus One-Vs-Rest (b)	23

Índice de Tabelas

Taxonomia das <i>features</i> do <i>dataset</i>	11
Definição dos Pipelines de Preparação de Dados testados	16
Impacto das Estratégias de Tratamento de Dados e Classes	16
Métricas de pureza por cluster (K-Means)	19
Resumo comparativo dos resultados experimentais (Validação Local vs. Kaggle)	21
Configurações e hiperparâmetros dos modelos utilizados.	22
Comparação de robustez: Baseline vs Técnicas de Balanceamento	24

1 Introdução

A gestão eficiente da mobilidade urbana constitui um dos desafios primordiais das cidades contemporâneas, onde a modelação do fluxo de tráfego assume um papel preponderante no planeamento de infraestruturas e na mitigação de impactos ambientais. O presente relatório debruça-se sobre este domínio, focando-se especificamente na previsão do fluxo de tráfego rodoviário na cidade do Porto, um problema caracterizado pela sua elevada complexidade estocástica e comportamento não-linear.

O objetivo central do projeto consiste no desenvolvimento e otimização de modelos de Aprendizagem Automática (*Machine Learning*) capazes de inferir, com elevada precisão, o nível de congestionamento num determinado momento. O problema é formalizado como uma tarefa de classificação multiclasse, onde a variável alvo, a diferença entre a velocidade teórica em fluxo livre e a velocidade real observada, é categorizada em cinco níveis ordinais (*None, Low, Medium, High e Very_High*). Para tal, são explorados dados heterogêneos que incluem variáveis temporais, condições meteorológicas e registos históricos de circulação.

Metodologicamente, o trabalho bifurca-se em duas vertentes complementares: uma fase analítica, orientada para a exploração de dados (*Exploratory Data Analysis*) e extração de conhecimento sobre os padrões de mobilidade, e uma vertente competitiva, materializada na participação num desafio no Kaggle, onde a robustez e a capacidade de generalização dos modelos preditivos são postas à prova.

A relevância deste estudo transcende o trabalho académico, uma vez que a capacidade de antecipar padrões de congestionamento oferece ferramentas valiosas para a otimização da rede rodoviária, contribuindo potencialmente para a redução dos tempos de deslocação, a diminuição do consumo energético e a mitigação da pegada ecológica urbana.

2 Metodologia

A metodologia que sustenta o desenvolvimento deste projeto fundamenta-se no ciclo padrão **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), devidamente adaptado às especificidades do contexto académico. Esta abordagem não linear e iterativa permitiu uma evolução contínua das soluções propostas, articulando-se nas seguintes etapas fundamentais:

Definição do Problema – Formalização dos objetivos do estudo, compreendendo a natureza estocástica da previsão de tráfego e estabelecendo as métricas de sucesso que guiam as decisões de modelação.

Observação e Ingestão de Dados – Análise exploratória preliminar destinada a compreender a semântica e a estrutura estatística das fontes de dados, assegurando a correta ingestão e validação da integridade dos registos.

Preparação dos Dados – Implementação de *pipelines* de pré-processamento robustos, abrangendo a imputação de valores em falta, normalização e, crucialmente, a *Feature Engineering* para extração de padrões latentes.

Modelação – Desenvolvimento e treino de diversos algoritmos de *Machine Learning*, com otimização rigorosa de hiperparâmetros recorrendo a estratégias de *Grid Search* e *Cross Validation*.

Avaliação – Análise crítica do desempenho dos modelos, confrontando a robustez na validação local com a capacidade de generalização demonstrada nas submissões na plataforma Kaggle.

Salienta-se a natureza cíclica desta metodologia, onde os *insights* obtidos na fase de avaliação despoletaram frequentes revisões nas etapas de preparação e modelação, num processo de refinamento sucessivo.

3 Definição do Problema

A modelação e previsão do fluxo de tráfego rodoviário representam desafios de elevada complexidade na engenharia de sistemas e ciência de dados, caracterizando-se pela sua natureza estocástica e não-linear. O presente trabalho debruça-se sobre a previsão do nível de congestionamento rodoviário da cidade do Porto, visando a criação de modelos preditivos que auxiliem na mitigação dos impactos negativos associados a esta saturação.

3.1 Contexto do Problema

O estudo fundamenta-se num *dataset* que agrega registos de tráfego recolhidos na cidade do Porto durante um período temporal significativo, compreendido entre 24 de julho de 2018 e 2 de outubro de 2019. A estrutura dos dados não se limita a leituras de sensores isolados, refletindo, sim, uma métrica agregada do estado do trânsito, resultante do agrupamento de diversos troços rodoviários. Esta agregação permite uma visão macroscópica da fluidez de circulação na cidade, capturando padrões sazonais e comportamentais ao longo de mais de um ano de observação.

3.2 Objetivo Principal

O objetivo primordial do projeto consiste no desenvolvimento e otimização de algoritmos de Aprendizagem Automática supervisionada, capazes de prever a variável alvo `average_speed_diff`. O problema é formalizado como uma tarefa de classificação multiclasse, onde o estado do trânsito é categorizado numa escala ordinal de cinco níveis:

- **None** – Ausência de congestionamento (velocidade real próxima da ideal).
- **Low** – Trânsito ligeiro, com impacto residual na velocidade média.
- **Medium** – Trânsito moderado, indicando o início de saturação da via.
- **High** – Trânsito intenso, com redução significativa da velocidade de circulação.
- **Very_High** – Congestionamento severo ou paralisação do fluxo rodoviário.

3.3 Relevância do Problema

A capacidade de antecipar estados de tráfego reveste-se de extrema importância, apresentando implicações práticas diretas em quatro dimensões fundamentais:

- **Gestão de Tráfego** – Potencia a implementação de *Intelligent Transport Systems* (ITS), permitindo uma regulação dinâmica de semáforos e o desvio preventivo de fluxos.
- **Planeamento Urbano** – Fornece dados analíticos para fundamentar decisões estratégicas sobre a expansão de infraestruturas e políticas de mobilidade pública.
- **Sustentabilidade** – Contribui para a redução da pegada ecológica urbana, uma vez que a otimização do fluxo minimiza o tempo de paragem dos veículos e, consequentemente, as emissões de gases com efeito de estufa (CO_2) e o consumo de combustível.
- **Qualidade de Vida** – Visa a redução dos tempos de deslocação pendular e dos níveis de stress dos cidadãos.

3.4 Métrica de Avaliação

A estratégia de avaliação de desempenho dos modelos foi estruturada para garantir não apenas a maximização da taxa de acerto global, mas também a robustez na deteção de todas as classes de tráfego. O processo de validação assenta numa abordagem *dual*:

1. Métrica Primária (Critério de Otimização) – Definiu-se a *Accuracy* (Percentagem de Acerto) como critério principal de seleção e *ranking* na competição, visto que, esta métrica quantifica a proporção de previsões corretas em relação ao total de observações, sendo a referência direta para a validação externa na plataforma Kaggle (*Blind Test Set*).

2. Métricas Complementares (Diagnóstico Interno) – Reconhecendo que a *Accuracy* pode ser uma métrica enganadora em cenários de desequilíbrio severo de classes, a validação interna incorporou uma análise multidimensional detalhada. Para cada modelo, avaliou-se:

Recall – Fundamental para aferir a aptidão do modelo em identificar exaustivamente as instâncias das classes raras, por exemplo, assegurar que todas as situações de trânsito *Very_High* são detetadas, evitando falsos negativos.

F1-Score – A média entre *Precision* e *Recall*, utilizada para encontrar o equilíbrio entre a precisão da classificação e a abrangência da deteção, penalizando modelos enviesados para as classes maioritárias.

Support – A contagem de ocorrências reais de cada classe no conjunto de validação, essencial para ponderar a importância relativa dos erros e interpretar corretamente as métricas anteriores através de médias ponderadas.

Esta abordagem abrangente, possibilitou discernir entre modelos que se limitam a replicar a distribuição das classes dominantes e aqueles que captam a lógica estrutural do tráfego.

4 Observação e Ingestão

Esta etapa incidiu sobre a análise preliminar das fontes de dados fornecidas, visando compreender a sua estrutura semântica, volumetria e qualidade intrínseca. A análise exploratória detalhada permitiu identificar os desafios que moldaram a estratégia de pré-processamento, nomeadamente o desequilíbrio de classes e a mistura de padrões.

4.1 Fonte de Dados

Os dados foram disponibilizados no âmbito da competição "ML@DAA" na plataforma Kaggle, estando divididos em dois conjuntos distintos:

- `training_data.csv` – Conjunto de treino contendo 6812 registos supervisionados.
- `test_data.csv` – Conjunto de teste, composto por 1500 registos não rotulados.
- `example_submission.csv` – Ficheiro auxiliar exemplificativo do formato de submissão requerido.

4.2 Análise de Dados e Taxonomia

O dataset é composto por variáveis heterogêneas que foram categorizadas em três dimensões principais, conforme detalhado na Tabela 1.

Tabela 1 Taxonomia das *features* do *dataset*

Categoria	Variáveis	Descrição
Temporais	<code>record_date</code> , <code>city_name</code>	Identificação temporal e localização.
Tráfego	<code>average_speed_diff</code> , <code>average_free_flow_speed</code> , <code>average_time_diff</code>	Métricas de velocidade e tempo de deslocação.
Meteorológicas	<code>luminosity</code> , <code>average_temperature</code> , <code>average_atmosp_pressure</code> , <code>average_humidity</code> , <code>average_wind_speed</code> , <code>average_cloudiness</code>	Condições atmosféricas no momento do registo.

4.3 Visualização e Insights Críticos

A prospeção visual dos dados permitiu decodificar padrões latentes e relações de dependência, fundamentando as decisões estratégicas adotadas nas fases subsequentes de modelação.

4.3.1 Distribuição do Alvo e Desequilíbrio

A análise exploratória da variável alvo (Figura 1) revelou um desequilíbrio severo na distribuição das classes. Observa-se que as categorias *None* e *Medium* dominam o *dataset* (representando cerca de 56% dos registos), enquanto as classes críticas para a gestão de tráfego, *High* e *Very High*, são minoritárias.




Figura 1: Distribuição dos dados

Dado este desequilíbrio foi realizada uma experiência, onde se testou a aplicação de *Oversampling* sintético (SMOTE). Contudo, essa técnica resultou numa degradação da performance (com um Diff positivo de +0.00931). A análise sugere que a criação de exemplos artificiais em zonas de fronteira densa introduziu mais ruído do que sinal útil. Consequentemente, concluiu-se que o modelo beneficia mais de aprender com a distribuição real, recorrendo a algoritmos de *Boosting* intrinsecamente robustos ao desequilíbrio, em detrimento de técnicas de reamostragem artificial.

4.3.2 Matriz de Correlação e SHAP Values

A análise de correlação cruzada (Figura 2), validada posteriormente pelos resultados de importância de variáveis (*SHAP Values*), permitiu isolar os principais determinantes da previsão:




Figura 2: Matriz de Correlação

- **Fator Determinante:** A variável `average_time_diff` apresenta a correlação positiva mais forte com o congestionamento. Atrasos temporais elevados validam-se como o indicador primário de tráfego *High*.
- **Variância Nula:** Identificou-se que a variável `city_name` possui o valor único "Porto" em todo o conjunto de treino, não conferindo qualquer valor preditivo, tendo sido removida.
- **Fatores Climáticos:** Variáveis como `average_rain` demonstraram uma correlação residual, indicando que o tráfego é ditado maioritariamente por padrões temporais (hora de ponta) e comportamentais, mais do que por condições atmosféricas ligeiras.

4.3.3 Análise de Clustering e Sobreposição

Uma das descobertas mais relevantes para a estratégia de modelação (Experiência 9) foi obtida através de algoritmos de *Clustering* não-supervisionado. A projeção dos dados evidenciou que não existem fronteiras lineares claras entre as classes *Medium* e *High*.

Esta mistura de classes no espaço vetorial justifica a necessidade imperativa de utilizar modelos de *Ensemble* (*Stacking*) e estratégias de decomposição (*One-Vs-Rest*). Apenas estes métodos são capazes de traçar as fronteiras de decisão não-lineares complexas necessárias para separar o que algoritmos simples, como SVM linear ou K-Means, não conseguem isolar.

5 Preparação de Dados

5.1 Tratamento de Atributos Categóricos

- **Variáveis Irrelevantes ou Redundantes** – Os atributos `city_name`, `average_rain` e `average_precipitation` foram removidos. O primeiro por apresentar variância nula (valor único "Porto") e os restantes por excesso de valores nulos (cerca de 90%) e redundância estatística. A variável `record_date` foi também removida do conjunto final após a extração de todas as características temporais relevantes, simplificando o modelo sem perda de capacidade preditiva.
- **Codificação da Luminosidade** – A variável `luminosity` foi transformada através de *Label Encoding* ordinal, mapeando a intensidade luminosa para uma escala numérica: **DARK** (0), **LOW_LIGHT** (1) e **LIGHT** (2). *Missing values* foram imputados como **LIGHT** (2), assumindo-se condições de luz diurna padrão para evitar enviesamento em períodos de visibilidade normal.

5.2 Tratamento de Missing Values e Conversão Numérica

Para garantir a robustez do *pipeline*, aplicou-se a conversão `pd.to_numeric(errors='coerce')` em variáveis como `average_temperature` e `average_wind_speed`. Os valores nulos resultantes ou pré-existentes foram preenchidos com 0, permitindo que os modelos baseados em árvores (*XGBoost* e *LightGBM*) tratem a ausência de sinal de forma natural e sem perda de registos.

5.2.1 Caso Especial – `average_cloudiness`

Dada a elevada percentagem de valores nulos nesta variável, optou-se por uma abordagem de Categorização Informativa. Em vez de uma imputação estatística (média/mediana), preencheram-se os campos NULL com a categoria NONE. Esta estratégia fundamenta-se na hipótese de que a ausência de registo de nebulosidade pode constituir, por si só, um padrão preditivo relevante para o estado do tráfego.

5.3 Feature Engineering

A transformação da variável `record_date` permitiu a criação de novos atributos estruturados para capturar a dinâmica temporal cíclica e os períodos críticos de tráfego urbano.

5.3.1 Representação do Dia da Semana

Para evitar uma hierarquia artificial entre dias, o `dia_semana` foi processado via *One-Hot Encoding*, resultando em características independentes (ex: `DAY_0`, `DAY_1`). Esta técnica permite ao modelo capturar comportamentos

específicos, como o impacto diferenciado das manhãs de segunda-feira face ao fluxo de fim de semana.

5.3.2 Indicadores de Períodos Críticos (Flags)

Foram criadas variáveis binárias (0 ou 1) baseadas no conhecimento do domínio para destacar períodos de maior pressão no fluxo rodoviário:

- **is_rush_hour** – Identifica as horas de ponta convencionais (7h–9h e 17h–19h).
- **is_weekend** – Identifica o fim de semana (Sábado e Domingo).

5.3.3 Codificação Cíclica (Cyclical Encoding)

Para assegurar a continuidade temporal, as horas e os meses foram convertidos para coordenadas sinusoidais (*Seno* e *Cosseno*). Este método garante que o modelo interprete o tempo como um ciclo, reconhecendo que as 23:00 e as 00:00 (ou Dezembro e Janeiro) são adjacentes na realidade:

$$X_{\sin} = \sin\left(\frac{2\pi \cdot X}{\max(X)}\right), \quad X_{\cos} = \cos\left(\frac{2\pi \cdot X}{\max(X)}\right) \quad (5.1)$$

5.4 Normalização e Escalonamento

Como etapa final da preparação, utilizou-se o **MinMaxScaler** para normalizar todas as características numéricas. Este processo escala os dados para o intervalo $[0, 1]$, prevenindo que variáveis com magnitudes elevadas (como a pressão atmosférica ou humidade) dominem o processo de aprendizagem em detrimento de variáveis com intervalos menores, como as coordenadas cíclicas.

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (5.2)$$

5.5 Análise Comparativa de Estratégias

De forma a isolar o impacto do pré-processamento na capacidade de aprendizagem dos modelos, definimos e testámos diferentes *pipelines* de transformação. Esta abordagem sistemática permitiu validar as escolhas metodológicas descritas anteriormente.

Conclusões da validação experimental:

1. **Superioridade da Prep. B** – A inclusão de engenharia de atributos avançada (codificação cíclica e flags) revelou-se fundamental para a performance do modelo, superando a *Baseline* simples. A preservação da continuidade temporal (23h $\approx$ 00h) permitiu capturar melhor os padrões noturnos.

Tabela 2 Definição dos Pipelines de Preparação de Dados testados

ID	Designação	Resumo das Técnicas
Prep. A	<i>Baseline</i>	Limpeza básica, imputação informativa de 'NONE' e MinMaxScaler.
Prep. B	<i>Feature Eng.</i>	Prep. A + Cyclical Encoding, Domain Flags e One-Hot Encoding.
Prep. C	<i>Balancing</i>	Prep. B + SMOTE.

2. **Ineficácia do SMOTE (Prep. C)** – Contrariamente ao esperado, a introdução de dados sintéticos degradou a performance (CV baixou de 0.814 para 0.809, ver Tabela 3). Isto indica que o SMOTE introduziu ruído nas fronteiras de decisão em vez de reforçar a distinção entre classes.
3. **Seleção Final** – Em virtude destes resultados, o pipeline de transformação da **Prep. B** foi o selecionado para treinar os modelos realizados ao longo do projeto.

Tabela 3 Impacto das Estratégias de Tratamento de Dados e Classes

Exp	Estratégia	CV Score	Kaggle	Δ (Diff)
–	<i>Baseline (XGB+LGBM)</i>	0.81489	0.82666	-0.01177
1	SMOTE (Balanceamento)	0.80931	0.80000	+0.00931
11	Pesos Manuais (Hard Weights)	0.80931	0.81333	-0.00402

5.6 Estratégia de Otimização de Hiperparâmetros

Para refinar o desempenho dos modelos de *Stacking*, explorámos duas abordagens distintas de sintonização de hiperparâmetros: a procura exaustiva (*Grid Search*) e a procura estocástica (*Randomized Search*).

5.6.1 Limitações da Procura Exaustiva (Grid Search)

Na Experiência 33, aplicámos o `GridSearchCV` combinado com `TimeSeriesSplit`. Embora esta técnica garanta a descoberta do ótimo global dentro da grelha definida, observámos dois problemas críticos:

1. **Custo Computacional:** A complexidade exponencial da grelha ($192 \text{ combinações} \times 5 \text{ folds}$) resultou em tempos de treino proibitivos, especialmente em modelos complexos de *Ensemble*.

2. **Overfitting aos Folds de Validação:** Verificámos que os parâmetros ótimos selecionados pelo Grid Search tendiam a ajustar-se excessivamente ao ruído dos dados de validação local. Isto resultou num fenómeno de *over-optimization*, onde o score de CV aumentava, mas a capacidade de generalização no conjunto de teste (Kaggle) diminuía.

5.6.2 Eficiência da Procura Aleatória (Randomized Search)

Para mitigar estes problemas, adotámos o `RandomizedSearchCV` (Experiência 37) para os modelos mais pesados. Esta abordagem, ao amostrar um número fixo de configurações aleatórias, permitiu:

- **Eficiência:** Explorar um espaço de hiperparâmetros mais vasto com uma fração do custo computacional.
- **Regularização Implícita:** Ao não testar exaustivamente todas as micro-variações, a procura aleatória evitou mínimos locais demasiado específicos, selecionando configurações mais robustas e generalistas.

Em suma, a otimização estocástica revelou-se superior para este problema, equilibrando melhor o *trade-off* entre tempo de treino e generalização do *Grid Search*.

6 Modelação

Nesta secção, apresentamos o processo experimental iterativo que conduziu à seleção da arquitetura final do modelo preditivo. A estratégia de modelação não foi linear, tendo partido de uma abordagem exploratória para identificar as limitações dos dados (como o ruído e a sobreposição de classes) e evoluiu para arquiteturas desenhadas especificamente para mitigar esses problemas.

As experiências foram avaliadas com base em duas métricas principais: a precisão média na validação cruzada local (CV) para garantir a estabilidade, e a pontuação no conjunto de teste público (Kaggle) para aferir a capacidade de generalização.

6.1 Análise de Padrões e Não-Supervisionada

Para além da maximização das métricas de desempenho preditivo, é fundamental compreender a estrutura latente dos dados e os mecanismos de decisão dos modelos. Enquanto a secção anterior se focou no "quê" (a previsão), esta secção foca-se no "porquê" e no "como".

Adotamos aqui uma abordagem exploratória e não-supervisionada para investigar a topologia do espaço vetorial. O objetivo é duplo: primeiro, verificar se as classes de tráfego possuem fronteiras geométricas naturais ou se existem sobreposições que justifiquem a complexidade dos modelos necessários; segundo, identificar quais as variáveis físicas (*features*) que exercem maior influência na distinção entre os diferentes níveis de congestionamento.

6.1.1 Experiência 9: Análise de Clustering e Sobreposição de Classes

Para investigar a viabilidade de modelos lineares ou de segmentação simples, aplicámos o algoritmo K-Means ($k = 5$) sobre o dataset normalizado. O objetivo foi verificar se os níveis de trânsito formam grupos naturais distintos no espaço vetorial.

A Figura 3 apresenta a projeção dos dados em 2D utilizando PCA (Principal Component Analysis). Os marcadores vermelhos ("X") representam os centroides calculados pelo algoritmo.




Figura 3: Visualização da projeção PCA e dos centroides gerados pelo K-Means

Visualmente, observa-se uma forte sobreposição entre as classes, especialmente entre *Medium*, *High* e *Very High*. Para quantificar esta "confusão", calculámos a Pureza dos Clusters (Tabela 4), que mede a percentagem da classe predominante em cada grupo criado.

Tabela 4 Métricas de pureza por cluster (K-Means)

Cluster ID	Classe Dominante Real	Pureza (%)	Interpretação
0	Medium	40.48%	Confusão Elevada
1	None	54.33%	Mistura Considerável
2	Medium	38.47%	Confusão Elevada
3	Medium	34.77%	Confusão Severa (High misturado)
4	None	60.66%	Melhor separação, mas insuficiente

Concluimos que a baixa pureza (máximo de 60.66%) e a sobreposição gráfica demonstram que as fronteiras de decisão não são geométricas simples. Isto justifica o insucesso observado na Experiência 10 (SVM) e valida a aposta em modelos de *Stacking* e *Boosting*, capazes de traçar fronteiras de decisão complexas.

6.2 A Tentativa com Deep Learning e o Overfitting

Apesar da popularidade das Redes Neurais em problemas complexos, a sua aplicação neste projeto revelou as limitações impostas pela dimensão do dataset.

Na Experiência 2, integramos um *Multi-Layer Perceptron* (MLPClassifier) no nível base do Stacking. Embora o desempenho local (CV) tenha subido ligeiramente para 0.81700, o resultado no Kaggle piorou face ao modelo de

referência. Isto indicou um início de *overfitting*, onde a rede começou a memorizar o ruído do treino em vez de generalizar padrões.

Posteriormente, na Experiência 8, tentámos otimizar uma rede neuronal pura (Deep Learning isolado), ajustando o *Learning Rate* e o número de camadas ocultas. Os resultados foram consistentemente inferiores aos métodos de *Ensemble* de árvores (Gradient Boosting). Conclui-se que, com apenas cerca de 6800 registos de treino, os dados são insuficientes para convergir os pesos de uma rede profunda de forma eficaz sem recorrer a *Data Augmentation* agressivo, que por sua vez (como visto na Exp. 1) introduz ruído prejudicial.

6.3 Otimização de Ensembles e AutoML

Nesta fase, procurámos refinar o equilíbrio entre viés (*bias*) e variância. Na Experiência 5, tentámos diversificar o nosso *Stacking* adicionando um *RandomForestClassifier* aos modelos de *Boosting* (XGBoost e LightGBM). O objetivo era combinar a força do *Bagging* (redução de variância) com o *Boosting*.

Contudo, a validação cruzada resultou numa accuracy de 0.81430, ligeiramente inferior à do modelo vencedor original (0.81489). Concluimos que o *RandomForest*, sendo um modelo menos capaz de capturar nuances subtis nos dados de tráfego do que o *Gradient Boosting*, acabou por diluir a precisão das votações, não justificando a sua inclusão nem a submissão no Kaggle.

Na Experiência 7, utilizámos a ferramenta de AutoML *PyCaret* para explorar arquiteturas alternativas. O algoritmo sugeriu o *Extra Trees Classifier* como o modelo mais promissor no treino. Contudo, ao validarmos manualmente, verificámos que este sofria de *overfitting* severo, apresentando pontuações de treino quase perfeitas que não se traduziam no conjunto de teste público.

Para contrariar a complexidade, realizámos a Experiência 6, onde simplificámos o modelo vencedor (reduzindo a profundidade do XGBoost e o número de folhas do LightGBM). O resultado foi uma descida do Cross-Validation para 0.80828, indicando que entrámos em zona de *underfitting*.

A Experiência 6b (adição do CatBoost) resultou num empate técnico com o modelo vencedor no Kaggle. Pelo princípio da *Navalha de Occam*, optámos por descartar o CatBoost, dado que aumentava a complexidade computacional e o tempo de treino sem trazer ganho de performance (Diff nulo).

6.4 A Solução Especialista (One-Vs-Rest)

A fase final focou-se em arquiteturas heterogêneas para combater a sobreposição de classes identificada na análise de Clustering (Secção 6.1.1).

A Experiência 10 testou a inclusão de um SVM (*Support Vector Machine*) no *Stacking*. O desempenho degradou-se (Diff: -0.01133), corroborando a análise da Figura 3: como não existem margens de separação claras entre as classes *Medium* e *High*, o SVM falha na construção de hiperplanos de suporte robustos.

A solução mais robusta emergiu na Experiência 12, onde abandonámos a abordagem monolítica em favor de uma estratégia *One-Vs-Rest* (OVR). Treinámos 5 classificadores independentes, cada um especializado em distinguir uma única classe das restantes.

Esta abordagem revelou-se superior porque simplifica a complexidade topológica do problema: enquanto um classificador multiclasse tenta traçar um mapa completo de todas as fronteiras simultaneamente num espaço ruidoso, a estratégia OVR isola cada decisão numa pergunta binária simples (ex: 'É High ou não?'). Esta simplificação permitiu reduzir drasticamente o ruído e a confusão entre classes adjacentes, tornando cada classificador um Especialista.

Finalmente, na Experiência 13, aplicámos *CalibratedClassifierCV* para ajustar as probabilidades de saída. Embora tenha melhorado a fiabilidade estatística das previsões (log-loss menor), não alterou significativamente a Accuracy final, confirmando que o limite de performance reside na separabilidade dos dados e não na calibração do modelo.

6.5 Síntese de Resultados e Reprodutibilidade

Apresentamos abaixo a súmula de todas as experiências realizadas, destacando a evolução da performance e as conclusões críticas que motivaram cada decisão, bem como os detalhes técnicos para reprodução.

Tabela 5 Resumo comparativo dos resultados experimentais (Validação Local vs. Kaggle)

Exp ID	Técnica / Modelo	CV (Local)	Kaggle	Δ Diff	Conclusão Principal
1	Balanceamento (SMOTE)	0.80931	0.80000	0.00931	Introdução de ruído; Piorou a performance.
2	Stacking + MLPClassifier	0.81700	0.82666	-0.00966	Overfitting ligeiro; Dataset pequeno para DL.
4	Ensemble Heterogéneo (KNN+NB)	0.81547	0.82666	-0.01119	Inferior ao Boosting puro.
5	Stacking (Baseline) + RandomForest	0.81430	–	–	CV inferior à baseline (0.8149); Sem ganho.
6	Stacking (Reduzido: XGB+LGBM)	0.80828	–	–	Underfitting; Modelo original é mais robusto.
6b	Stacking (Baseline) + CatBoost	0.81415	0.82666	-0.01251	Redundante; Mesma pontuação, maior complexidade.
7	AutoML (PyCaret - ExtraTrees)	–	–	–	Scores altos no treino indicaram Overfitting severo.
8	MLP Otimizada (DL Puro)	–	< 0.82	–	Inferior aos Ensembles; Dados insuficientes.
10	Stacking (Baseline) + SVM	0.81533	0.82666	-0.01133	SVM falha em encontrar margens no ruído.
11	Stacking c/ Pesos Manuais	0.80931	0.81333	-0.00402	Forçar pesos distorceu a probabilidade real.
12	One-Vs-Rest (Especialistas)	0.81033	0.82666	-0.01633	Melhor estabilidade e generalização.
13	Calibração de Probabilidades	0.81092	0.82222	-0.01130	Ligeira melhoria na fiabilidade, mas não no score.

6.6 Detalhes de Reprodutibilidade (Hiperparâmetros)

Para garantir a reprodutibilidade científica dos resultados e permitir a validação futura das conclusões, a tabela 6 detalha as configurações específicas dos algoritmos utilizados nas experiências mais relevantes.

Tabela 6 Configurações e hiperparâmetros dos modelos utilizados.

Exp ID	Modelo / Técnica	Configuração e Hiperparâmetros Chave
1	SMOTE (Sampling)	k_neighbors=5, sampling_strategy='auto', Random State=42
2	MLP (no Stacking)	Layers=(64, 32), Activ='relu', Solver='adam', Max Iter=500
4	Ensemble Heterogêneo	KNN: n_neighbors=10; GaussianNB: Default parameters
5	Random Forest	n_estimators=100, max_depth=10, n_jobs=-1
6	CatBoost	iterations=200, depth=6, learning_rate=0.05
8	MLP (Otimizada)	Layers=(50, 50), Activ='tanh', Solver='adam', LR=0.001
10	SVM (Stacking)	Kernel='rbf', C=1.0, Gamma='scale', Probability=True
11	Pesos Manuais	Pesos: {Very High: 2.0, High: 1.5, Low: 1.3, Med: 1.0, None: 0.8}
12	One-Vs-Rest (Final)	Base Estimator: XGBoost (Depth=5, LR=0.08, Est=100)
13	Calibração	Method='sigmoid' (Platt Scaling), CV=5

7 Avaliação

A avaliação final focou-se na capacidade do modelo distinguir as classes críticas, onde o custo do erro é maior para a gestão de tráfego. A estratégia *One-Vs-Rest* (Experiência 12) revelou-se a mais equilibrada.

7.1 Análise de Erros e Matriz de Confusão

A Figura 4 (b) ilustra a matriz de confusão obtida pelo modelo final. A análise da diagonal principal evidencia uma predominância de Verdadeiros Positivos transversalmente a todas as classes, indicando uma consistência sólida nas previsões, mesmo nas classes minoritárias.




Figura 4: Comparação das matrizes de confusão: SMOTE (a) versus One-Vs-Rest (b)

7.1.1 O Problema do Ruído (SMOTE)

Como visível na Figura 4a, o uso de SMOTE (Exp. 1) introduziu ruído excessivo. Observa-se uma "mancha" difusa entre as classes *Medium* e *High*. O modelo, forçado a aprender com exemplos sintéticos, perdeu a capacidade de definir fronteiras claras, gerando um elevado número de Falsos Positivos nestas classes intermédias.

A tabela 7 reforça esta conclusão, mostrando que tanto o balanceamento sintético como a manipulação manual de pesos resultaram numa generalização inferior à baseline.

Tabela 7 Comparação de robustez: Baseline vs Técnicas de Balanceamento

Exp	Estratégia	CV Score	Kaggle	Δ (Diff)
–	Baseline (XGB+LGBM)	0.81489	0.82666	-0.01177
1	SMOTE (Balanceamento)	0.80931	0.80000	+0.00931
11	Pesos Manuais (Hard Weights)	0.80931	0.81333	-0.00402

7.1.2 Análise da Solução Final (Especialistas)

A estratégia de Especialistas (*One-Vs-Rest*) limpou a matriz de confusão (Figura 4b). A análise da diagonal principal evidencia uma predominância de Verdadeiros Positivos transversalmente a todas as classes. Destacamos três pontos críticos que validam a robustez desta solução para um ambiente de produção:

1. **Precisão na Classe Maioritária** – O modelo identificou corretamente 1997 instâncias da classe *None* (canto inferior direito), cometendo erros residuais. Isto garante que o sistema não gera falsos alarmes em situações de trânsito fluido, mantendo a credibilidade junto dos operadores.
2. **Erro "Seguro" no Trânsito Extremo** – Na classe crítica *Very High* (canto inferior esquerdo), o modelo acertou 387 vezes. O aspeto fundamental é a natureza do erro: nas 92 falhas registadas, o modelo classificou maioritariamente como *High*. Num contexto real de gestão de semáforos, este erro é aceitável, pois o sistema continua a desencadear medidas de mitigação de congestionamento, ao contrário do que aconteceria se o classificasse como *Low* (erro fatal).
3. **Eliminação de Erros Dispersos** – A grande maioria dos erros encontra-se agora adjacente à diagonal principal (ex: confundir *Medium* com *Low*). Não existem erros graves dispersos (como confundir *Very High* com *None*), o que prova que os classificadores especialistas aprenderam corretamente a ordinalidade e a fronteira de decisão progressiva do tráfego.

Em suma, a abordagem final mitigou o ruído das experiências iniciais, oferecendo uma previsão fiável onde os erros residuais possuem um impacto operacional reduzido.

8 Conclusão e Trabalho Futuro

8.1 Síntese do Trabalho Desenvolvido

Neste projeto, abordámos o desafio de previsão de fluxo de tráfego rodoviário, um problema caracterizado pela sua natureza estocástica e classes severamente desequilibradas. O desenvolvimento seguiu um processo iterativo rigoroso que totalizou 64 submissões na plataforma Kaggle.

Ao longo deste percurso, documentámos as 13 experiências mais relevantes, explorando desde modelos lineares simples a arquiteturas complexas de *Stacking*. Este esforço extensivo permitiu-nos alcançar a 10.^a posição na classificação geral. Mais relevante do que a classificação final, a análise de performance confirma que o nosso melhor modelo (Experiência 12 - *One-Vs-Rest*) atingiu uma pontuação de generalização que garantiria a 4.^a posição na competição, validando a robustez técnica e a competitividade da solução desenvolvida face às melhores abordagens.

Os objetivos propostos foram assim plenamente atingidos, resultando num sistema que prioriza a estabilidade sobre o ajuste excessivo aos dados de treino. A documentação dos hiperparâmetros (Secção 6.6) assegura a reprodutibilidade científica de todas as etapas.

8.2 Reflexão Crítica: A Lição dos Dados

A análise comparativa entre as diversas abordagens permitiu retirar conclusões fundamentais sobre os dados:

- **A Ineficácia do Balanceamento Sintético** – A aplicação de SMOTE (Exp. 1) degradou a performance. Isto sugere que a classe minoritária (*Very High*) não está isolada, mas sim misturada nas fronteiras das classes maioritárias. Criar pontos sintéticos nessas zonas apenas aumentou a confusão do classificador.
- **Limitações Geométricas (SVM)** – O insucesso do SVM com kernel RBF (Exp. 10) corroborou a análise de Clustering: não existem margens de separação claras entre os níveis de trânsito. O problema não é resolvível através de maximização de margens, mas sim através de fronteiras de decisão não-lineares e fragmentadas, típicas de Árvores de Decisão.
- **A Supremacia da Especialização** – A estratégia vencedora, *One-Vs-Rest* (Exp. 12), superou o *Stacking* tradicional ao decompor um problema complexo de 5 classes em 5 problemas binários simplificados. Ao treinar um Especialista focado apenas em distinguir, por exemplo, *High* de *Não-High*, o modelo conseguiu isolar o sinal do ruído de forma mais eficaz do que um modelo generalista.

8.3 Trabalho Futuro

Apesar da robustez da solução final, identificam-se vias promissoras para investigação futura, limitadas neste projeto pela dimensão do *dataset* (6800 registos):

1. **Feature Engineering Temporal (Lag Features)** – A incorporação de janelas deslizantes - trânsito na hora anterior, trânsito no mesmo dia da semana passada - capturaria a inércia temporal inerente ao fluxo rodoviário.
2. **Enriquecimento com Dados Externos** – A fusão com dados de calendários (feriados locais, eventos desportivos) e meteorologia detalhada ajudaria a explicar picos de trânsito que o modelo atual considera como ruído aleatório.
3. **Deep Learning com Mais Dados** – As redes neuronais (Exp. 2 e 8) falharam devido à escassez de dados. Num cenário de *Big Data*, arquiteturas recorrentes (LSTM ou GRU) seriam ideais para modelar a sequencialidade temporal que os modelos de árvore ignoram.

Em suma, este trabalho demonstra que, em problemas de classificação ruidosos e desequilibrados, a arquitetura do modelo (como a estratégia *One-Vs-Rest*) é frequentemente mais determinante do que a complexidade do algoritmo base.

Bibliografia

- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321-357.
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785-794). ACM.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., ... & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146-3154.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
- Ali, M. (2020). *PyCaret: An open source, low-code machine learning library in Python*. PyCaret.org.
- Shearer, C. (2000). The CRISP-DM model: the new blueprint for data mining. *Journal of Data Warehousing*, 5(4), 13-22.
- Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.